



SAE Prédiction d'une variable quantitative

ROSE CHAUVIN & CLARA DECROS

1 CE QU'ON A RETENU DU MACHINE LEARNING

Le Machine Learning, qui signifie littéralement « machine qui apprend », désigne une branche de l'intelligence artificielle permettant à une machine d'apprendre à partir des données et de ses erreurs, à l'instar de l'humain.

Pour cela, elle s'appuie sur des données issues d'observations ou de « tests » passés, qui constituent une forme de mémoire. À partir de ces données, l'algorithme cherche à identifier des relations entre différentes variables.

Ces tests peuvent prendre des formes variées selon le problème étudié (régression, classification, etc.), mais ils ont tous le même objectif : permettre à la machine d'établir des liens, souvent sous forme de corrélations ou de dépendances, entre certaines variables (ou combinaisons de variables) et un résultat final à prédire. Nous avons compris que le Machine Learning repose principalement sur les trois éléments cités dans le cours : les données, le modèle et l'algorithme. Les données sont essentielles, car la qualité des résultats dépend directement de leur qualité. Le modèle correspond à la forme mathématique choisie pour relier les variables explicatives à la variable que l'on cherche à prédire. Enfin, l'algorithme sert à ajuster les paramètres du modèle pour minimiser l'erreur et obtenir la meilleure prédiction possible. Un point important que nous avons retenu est la notion de généralisation : un bon modèle ne doit pas seulement bien fonctionner sur les données d'entraînement, mais aussi sur de nouvelles données. C'est pour cela qu'on sépare les données en plusieurs parties (apprentissage et test) afin d'évaluer réellement la performance du modèle et d'éviter le surapprentissage.

Dans le cadre de cette SAÉ, nous avons appliqué cette démarche à un problème de régression linéaire multiple. L'objectif était de prédire le diamètre d'une tumeur cancéreuse (variable Y) à partir de dix tests médicaux quantitatifs (X_1 à X_{10}). Nous avons comparé plusieurs modélisations (avec valeurs extrêmes, sans valeurs extrêmes et après écrêtement) afin d'évaluer l'impact de ces données atypiques sur la performance du modèle et de choisir la solution la plus pertinente.

Cependant, le Machine Learning soulève quelques points de vigilance. Un modèle surapprend lorsqu'il s'adapte trop précisément aux données d'entraînement. Par exemple, s'il mémorise des détails ou des anomalies spécifiques à ces données, il donnera de très bons résultats sur elles... mais échouera sur de nouvelles données. Autrement dit, il "apprend le bruit" plutôt que la vraie relation entre les variables.

À l'inverse, un modèle sous-apprend lorsqu'il est trop simple pour représenter correctement la relation entre les variables. Par exemple, si la vraie relation est complexe mais que l'on utilise un modèle trop basique, il ne pourra pas capter toutes les variations et fera des prédictions imprécises, même sur les données d'entraînement.

Cette étude nous a permis de comprendre que le Machine Learning ne consiste pas seulement à appliquer un modèle, mais à suivre une démarche complète : préparation des données, apprentissage, évaluation et comparaison des résultats pour justifier un choix final, comme nous allons le détailler dans les prochaines parties.

2 NOTRE DÉMARCHE DE RÉOLUTION

Dans le cadre de notre étude, nous avons cherché à analyser l'impact des valeurs extrêmes sur la performance d'un modèle de régression linéaire appliqué au jeu de données cancer_sae2026.csv. L'objectif principal était de comparer différentes stratégies de traitement des valeurs aberrantes afin d'identifier celle qui permet d'obtenir le modèle le plus pertinent et le plus robuste.

La première étape de notre démarche a consisté à préparer et nettoyer les données. Après l'importation du fichier, nous avons traité les valeurs manquantes en les remplaçant par la médiane de chaque variable. Ce choix méthodologique repose sur le fait que la médiane est moins sensible aux valeurs extrêmes que la moyenne, ce qui permet de limiter les biais dès la phase de prétraitement. Nous avons ensuite séparé les variables explicatives de la variable cible (y), en retirant également la variable identifiant, qui ne possède pas de valeur prédictive.

Afin d'évaluer précisément l'influence des valeurs extrêmes, nous avons construit trois modèles distincts reposant sur une régression linéaire. Dans la première approche, nous avons conservé l'ensemble des données après l'imputation, sans appliquer de traitement spécifique aux valeurs aberrantes. Ce modèle sert de référence pour mesurer l'effet des autres méthodes.

Dans la deuxième approche, nous avons choisi de supprimer les observations contenant des valeurs extrêmes. Pour les identifier, nous avons utilisé la méthode de l'intervalle interquartile (IQR). Pour chaque variable, nous avons calculé le premier quartile ($Q1$) et le troisième quartile ($Q3$), puis déterminé l'IQR ($Q3 - Q1$). Toute observation présentant au moins une valeur située en dehors de l'intervalle $[Q1 - 1,5 \times IQR ; Q3 + 1,5 \times IQR]$ a été supprimée.

Cette méthode permet d'obtenir un jeu de données plus homogène en éliminant les points atypiques susceptibles d'influencer fortement l'estimation des coefficients de la régression.

Dans la troisième approche, nous avons également détecté les valeurs extrêmes à l'aide de la méthode IQR, mais au lieu de supprimer les observations concernées, nous avons appliqué un écrêtement. Concrètement, les valeurs inférieures à la borne minimale ont été remplacées par cette borne, et les valeurs supérieures à la borne maximale ont été remplacées par la borne supérieure. Cette stratégie permet de conserver l'ensemble des observations tout en réduisant l'influence excessive des valeurs aberrantes.


Pour chacune des trois méthodes, nous avons séparé les données en un échantillon d'entraînement (80 %) et un échantillon de test (20 %). Les modèles ont été entraînés sur les données d'apprentissage puis évalués sur les données de test à l'aide du coefficient de détermination R^2 , qui mesure la proportion de la variance de la variable cible expliquée par le modèle. Des visualisations graphiques, notamment des boîtes à moustaches et des nuages de points comparant les valeurs réelles et prédites, ont également été réalisées afin d'analyser la distribution des variables et la qualité de l'ajustement.

Ainsi, notre démarche repose sur une comparaison structurée de trois stratégies de traitement des valeurs extrêmes — conservation, suppression et écrêtement — dans le but d'évaluer leur impact sur la performance et la robustesse du modèle de régression linéaire.


3 NOS RÉSULTATS

Dans le cadre de notre analyse, nous avons comparé les performances de trois modèles de régression linéaire construits selon différentes stratégies de traitement des valeurs extrêmes : conservation des valeurs aberrantes, écrêtement et suppression. L'évaluation a été réalisée à l'aide du coefficient de détermination R^2 , calculé sur un échantillon de test représentant 20 % des données.


Le modèle entraîné avec les valeurs extrêmes présente un coefficient R^2 de 0,9027. Ce résultat indique que 90,27 % de la variance de la variable cible est expliquée par le modèle. Bien que cette performance soit déjà élevée, l'analyse graphique montre une dispersion plus importante des points autour de la diagonale (valeurs réelles versus valeurs prédites), traduisant l'influence des observations atypiques sur l'estimation des coefficients. La régression linéaire étant sensible aux valeurs extrêmes, celles-ci peuvent légèrement perturber l'ajustement global.



Le modèle construit après écrêtement des valeurs extrêmes obtient un R^2 de 0,9041, soit une légère amélioration par rapport au modèle initial. Cette progression montre que limiter l'influence des valeurs aberrantes sans supprimer les observations permet d'améliorer la stabilité du modèle tout en conservant l'ensemble des données. L'écrêtement réduit la dispersion excessive tout en maintenant la richesse du jeu de données.



Enfin, le modèle sans les valeurs extrêmes, obtenu après suppression des observations atypiques à l'aide de la méthode IQR, présente la meilleure performance avec un R^2 de 0,9070. Ce résultat signifie que 90,70 % de la variance est expliquée par le modèle, ce qui constitue la performance la plus élevée parmi les trois approches. La suppression des valeurs extrêmes permet donc d'obtenir un modèle légèrement plus précis, car les points atypiques n'influencent plus l'estimation des paramètres.



Au regard des résultats, nous choisissons de retenir le modèle sans les valeurs extrêmes, car il présente le coefficient R^2 le plus élevé et offre donc la meilleure capacité explicative. Toutefois, l'écart entre les trois modèles reste relativement faible, ce qui montre que les valeurs extrêmes n'affectaient pas fortement la structure globale des données. Le choix de la suppression se justifie ici par la recherche de la performance maximale, mais dans un contexte où les valeurs extrêmes représenteraient des situations réelles et importantes, l'écrêtage pourrait constituer une alternative pertinente.

Ainsi, notre comparaison met en évidence que le traitement des valeurs extrêmes influence la performance du modèle, même si l'impact reste modéré dans notre cas.